

第一阶段：无感语音记录与总结助手

一、阶段定位

第一阶段的产品目标不是做一个功能完整的通用 Agent，也不是做一个始终主动说话的语音聊天机器人。

第一阶段只聚焦一件事情：

让用户在几乎不被打断的情况下，通过自然说话完成内容记录，并在结束后获得准确、清晰、可使用的转录与总结。

产品的核心关键词是：

无感、准确、快速、可打断、低操作成本。

“无感”不是一个单独功能，而是这款产品长期需要持续探索的核心体验标准。

二、什么叫“无感”

无感不等于完全没有界面，也不等于后台一直监听用户。

无感的本质是：

用户为了表达和记录，需要额外付出的操作、等待和注意力非常少。

具体包含六个方面。

1. 启动无感

用户不需要打开复杂页面、选择模式、创建文档，再开始说话。

理想状态下，通过一个动作即可启动：

- 按下键盘快捷键；
- 点击桌面悬浮球；
- 点击系统托盘图标；
- 点击鼠标侧键；
- 使用全局热键；
- 在移动端长按特定区域。

第一阶段优先验证：

全局快捷键 + 桌面悬浮入口。

这与用户使用微信 Fn 快捷输入的习惯比较接近，默认可以使用 Fn 快捷键触发，但同时必须支持用户自定义全局快捷键，学习成本低，也比打开完整软件更自然；在第一阶段应优先完成 Mac 端实现，并充分利用 macOS 的系统能力（如全局快捷键、菜单栏常驻入口、权限体系与音频 API），以保证体验的稳定性与低延迟；此外桌面悬浮球的设计可以参考“刘海屏”式的极简前端形态，在 Mac 上优先以菜单栏 + 刘海区域贴边浮层的方式实现低侵入、弱存在感的常驻交互入口，后续再扩展到 Windows 的贴边悬浮与系统托盘形态。

2. 说话无感

用户不应该为了适应系统，刻意使用标准普通话、短句或固定指令。

系统需要尽可能支持：

- 自然停顿；
- 口头语；
- 重复表达；
- 自我纠正；
- 中英文混合；
- 专有名词；
- 连续长时间表达；
- 说到一半改变主题。

例如用户说：

“我明天，呃，不对，是后天下午，要去面试那个凌和数智，岗位好像是产品市场，你先帮我记一下。”

系统应理解最终有效信息，而不是机械保留所有口误。

原始转录可以保留，但整理结果应完成语义修正。

3. 等待无感

用户说话时，系统应实时显示转写结果，但不能要求用户等待全部语音上传完成后才开始处理。

建议采用流式链路：

用户说话

- 音频流实时上传
- 流式语音识别
- 实时显示临时转录
- 语句稳定后修正文本
- 后台同步进行语义提取
- 用户结束后快速生成总结

需要区分两类文本：

临时转录

快速出现，可能存在错误，主要用于让用户确认系统正在工作。

稳定转录

经过上下文修正、标点恢复、专有名词纠正后的最终文本。

这样可以在速度和准确率之间取得平衡。

4. 打断无感

语音输出不是越多越好。

当 AI 正在说话时，用户需要能够随时插话。系统检测到用户开始说话后，应立即：

1. 停止或降低 AI 语音播放；
2. 保留已经表达的上下文；
3. 识别用户的新意图；
4. 判断用户是在补充、纠正，还是发起新任务；
5. 快速继续响应。

这一能力通常叫作：

Barge-in，语音打断。

它不是简单地停止播放，而是要正确处理被打断后的对话状态。

例如：

AI：“我已经帮你总结了今天的三项——”

用户：“等一下，不是今天，是昨天。”

系统应修正时间，而不是重新开始一场对话。

5. 结果无感

用户说完后，不应该还需要自己重新整理一遍。

系统应自动输出：

- 原始转录；
- 修正后的转录；
- 内容摘要；
- 关键事件；
- 用户做出的决定；

- 待办事项；
- 需要进一步确认的内容。

但第一阶段不能自动假设所有内容都是任务。

例如：

“我最近觉得应该看看 LangGraph。”

这可能只是一个想法，不一定是待办。

系统可以标记为：

- 想法：研究 LangGraph；
- 是否加入待办：等待用户确认。

6. 界面无感

产品不应该长期占据用户桌面的主要空间。

推荐采用三层界面形态。

第一层：静默状态

平时只在以下位置保留入口：

- 系统托盘；
- 菜单栏；
- 小型悬浮球；
- 全局快捷键。

不显示完整聊天窗口。

第二层：录音状态

启动后出现一个非常轻量的悬浮条：



● 正在聆听 实时转录内容…… 暂停 完成

悬浮条只显示：

- 当前录音状态；
- 简短实时转录；
- 麦克风状态；
- 暂停按钮；
- 结束按钮。

不在这个阶段展示复杂的聊天内容、侧边栏和功能入口。

第三层：结果状态

用户结束表达后，弹出结果卡片：

- 本次总结；
- 待办事项；
- 重要决定；
- 保存位置；
- “继续补充”入口；
- “纠正内容”入口。

用户可以立即关闭，内容仍在后台保存。

三、第一阶段的核心产品形态

产品首先是一款桌面端轻量工具，而不是传统的大型聊天软件。

建议产品由四个部分组成。

1. 桌面悬浮入口

负责快速启动和显示录音状态。

2. 全局快捷键

用户可自行配置，例如：

- 按住说话；
- 按一次开始，再按一次结束；
- 长按快捷键录入，松开后提交；
- 双击快捷键进入连续对话。

第一阶段需要测试不同模式，不能直接假定哪一种最好。

建议至少验证三种交互：

模式 A：按住说话

优点：

- 接近微信语音输入习惯；
- 用户容易理解；
- 不容易忘记结束录音。

缺点：

- 不适合较长表达；
- 长时间按键会疲劳。

模式 B：点击开始，点击结束

优点：

- 适合长时间表达；
- 操作简单。

缺点：

- 用户可能忘记关闭；
- 对隐私提示要求更高。

模式 C：语音活动自动结束

用户启动后直接说话，系统检测到一段时间没有声音后自动结束。

优点：

- 操作最少；
- 更接近无感体验。

缺点：

- 停顿可能被误判为表达结束；
- 需要较准确的语音活动检测。

第一版建议：

以“点击开始、点击结束”为默认模式，同时提供“按住说话”作为快速输入模式。

自动结束可以作为实验功能，而不是默认功能。

四、语音交互模式

第一阶段需要明确区分两种场景。

场景一：语音记录模式

系统主要负责听，不主动插话。

适用于：

- 记录想法；
- 面试复盘；
- 会议记录；
- 情绪表达；
- 灵感记录；
- 口述待办。

工作流程：

开始录音
→ 用户连续表达
→ 实时转录
→ 用户结束
→ 自动总结

这是第一阶段最重要、最应该先做好的模式。

场景二：语音对话模式

系统会通过语音回应用户，用户可以随时打断。

适用于：

- 讨论问题；
- 询问建议；
- 补充和修正信息；
- 拆解任务；
- 进行连续思考。

工作流程：

用户说话
→ 实时识别
→ 模型理解
→ 流式生成回复
→ 语音流式播放
→ 用户随时打断

第一版不能把两种模式混为一谈。

在记录场景中，AI 频繁说话反而会破坏无感体验。

因此建议默认进入“记录模式”，只有用户主动提问或切换后，才进入“对话模式”。

五、模型与 API 集成

这个产品必然需要进行 API 集成，但不要把所有能力都交给一个大模型完成。

建议拆成四种能力。

1. 语音活动检测 VAD

判断用户什么时候开始说话、什么时候停止说话。

它决定：

- 是否开始识别；
- 是否结束一个语句；
- 是否触发打断；
- 是否过滤环境噪声。

2. 语音识别 ASR

负责语音转文字。

重点评估：

- 中文准确率；
- 中英文混合准确率；
- 专有名词识别；
- 流式输出速度；
- 长语音稳定性；
- 标点恢复；
- 噪声环境表现；
- 说话人停顿处理。

3. 大语言模型 LLM

负责：

- 语义理解；
- 口误修正；
- 内容总结；
- 待办提取；
- 事件提取；
- 对话回复；
- 用户意图判断。

4. 语音合成 TTS

负责将 AI 回复转换为语音。

重点评估：

- 首个声音出现时间；
- 自然度；
- 情绪稳定性；
- 是否支持流式合成；
- 是否能快速停止；
- 中英文混读；

- 长文本语调。

完整链路为：

麦克风
→ VAD
→ 流式 ASR
→ 对话状态管理
→ LLM
→ 流式 TTS
→ 扬声器

如果只是记录总结，则不必每次调用 TTS：

麦克风
→ VAD
→ 流式 ASR
→ LLM 总结
→ 结果卡片

这样能降低延迟、成本和对用户的打扰。

六、Dify 在第一阶段的作用

Dify 可以用于快速检验产品逻辑，但不应直接被当作最终实时语音架构。

适合使用 Dify 验证：

- 总结提示词；
- 待办提取准确率；
- 事件结构化；
- 多模型效果对比；
- 不同工作流的输出质量；
- 用户输入进入不同处理链路的判断；
- 模型调用成本。

例如可以先建立一个工作流：

转录文本
→ 判断内容类型
→ 生成摘要
→ 提取事件
→ 提取待办
→ 检测不确定信息
→ 输出结构化 JSON

Dify 不适合承担的核心部分包括：

- 毫秒级音频流控制；
- 低延迟语音打断；
- 实时 VAD；
- 音频缓冲；
- TTS 播放中断；
- 桌面全局快捷键；
- 系统级悬浮窗口。

因此第一阶段可以采用：

桌面客户端

负责录音、快捷键、悬浮窗和实时状态

实时语音服务

负责 VAD、ASR 和音频流

Dify 工作流

负责总结、信息提取和模型效果验证

数据服务

负责保存转录、摘要、待办和用户设置

当验证完成后，再决定是否将 Dify 工作流迁移为自主后端服务。

七、第一阶段的验证方法

第一阶段不能只验证“能不能运行”，而要验证无感体验是否成立。

1. 准确率测试

准备真实语料，而不是标准测试句。

测试内容包括：

- 普通中文；
- 中英文混合；
- 产品和技术名词；
- 公司名称；
- 人名；
- 口语停顿；
- 自我修正；
- 较长独白；
- 安静和嘈杂环境。

例如：

“我们可以先用 Dify 验证，后面再考虑接 LiveKit，呃，不对，应该先验证 ASR。”

需要检查系统能否正确理解最终意图。

2. 响应速度测试

分别记录：

- 点击后到开始录音的时间；
- 说话后到出现首段文字的时间；
- 停止说话到稳定转录完成的时间；
- 结束录音到摘要出现的时间；
- 提问后到 AI 开始播放语音的时间；
- 用户打断后 AI 停止播放的时间。

3. 操作成本测试

统计完成一次记录需要：

- 点击几次；
- 是否需要切换窗口；
- 是否需要选择保存位置；
- 是否需要修改结果；
- 是否会打断原本的工作。

4. 主观无感评分

每次测试后让用户评价：

- 启动是否自然；
- 转录是否可信；
- 是否需要等待；
- 系统是否打断思考；
- 是否愿意每天使用；
- 相比微信语音输入是否更方便；
- 相比 ChatGPT 语音是否更适合记录任务。

八、第一阶段关键指标

输入体验

- 首段转录延迟；
- 最终转录准确率；
- 中英文混合准确率；
- 专有名词正确率；
- 用户手动修改率。

总结效果

- 摘要可用率；
- 待办提取准确率；
- 错误添加待办比例；
- 用户删除总结内容比例；
- 用户保存结果比例。

无感体验

- 平均启动步骤；
- 单次使用前置时间；
- 悬浮窗关闭率；
- 用户中途放弃率；
- 每日自然使用次数；
- 用户主动设置快捷键比例。

对话体验

- AI 首次语音响应延迟；
 - 打断识别成功率；
 - 打断后上下文保持率；
 - AI 被用户频繁打断的比例；
 - 用户选择关闭语音输出的比例。
-

九、修改后的第一阶段功能边界

必须完成

- 桌面全局快捷键；
- 轻量悬浮录音条；
- 实时语音转录；
- 中英文混合识别；
- 原始文本与修正文本；
- 自动摘要；
- 待办和重要信息提取；
- 结束后的轻量结果卡片；
- 历史记录；
- 基础语音问答；
- 用户打断 AI 语音；
- 用户主动删除记录；
- 明确的录音状态提示。

暂时不做

- 一直后台监听；
- 自动操作大量第三方软件；
- 多 Agent 协作；

- A2A;
 - 自动整理整个电脑文件;
 - 复杂个人知识图谱;
 - 全天主动提醒;
 - 完整情绪分析系统;
 - 自动发送邮件和消息;
 - 完全无人确认的任务执行。
-

十、第一阶段的一句话定义

一款常驻桌面的无感语音助手，让用户通过一次快捷操作自然说话，系统实时转录，并在结束后自动生成可用的总结、待办和重要记录。

第一阶段真正需要证明的不是“我们的 Agent 有多聪明”，而是：

用户在产生想法的那一刻，是否愿意自然地打开它，并相信自己说过的话会被准确记录和整理。